RAPPORT HEBDOMADAIRE

Semaine 1 : Setup & Exploration des Données

Projet	RadiSense AI
Tagline	Where Radiology Meets Intelligence
Étudiante	Syrine Trabelsi
Professeur	Haythem Ghazouani
Module	Deep Learning / Computer Vision
Durée	8 semaines
Période	6 février - 15 février 2026
Status	✓ Semaine 1 COMPLÉTÉE

Généré le 15/02/2026 à 08:38

TABLE DES MATIÈRES

1. Résumé Exécutif
2. Objectifs de la Semaine 1
3. Réalisations Détaillées
3.1. Configuration du Projet
3.2. Setup Environnement Technique
3.3. Téléchargement du Dataset
3.4. Exploration des Données (EDA)
4. Livrables de la Semaine
5. Métriques et Statistiques
6. Difficultés Rencontrées et Solutions
7. Validation des Objectifs
8. Prochaines Étapes (Semaine 2)

1. RÉSUMÉ EXÉCUTIF

La première semaine du projet RadiSense AI a été consacrée à la mise en place complète de l'infrastructure du projet et à l'exploration approfondie du dataset ChestX-ray14. Tous les objectifs fixés ont été atteints avec succès, établissant une base solide pour les phases suivantes de développement et d'entraînement des modèles.

Points Clés :

- ✓ Structure de projet complète créée et documentée
- ✓ Environnement de développement configuré (Python 3.11, venv, packages)
- ✓ Dataset complet téléchargé (112,120 images, 42 GB)
- ✓ Exploration des données réalisée avec visualisations
- ✓ Repository GitHub initialisé avec 8 commits
- ✓ GPU NVIDIA détecté et confirmé pour l'entraînement
- ✓ Documentation technique complète (PROJECT_OVERVIEW.md, README.md)

2. OBJECTIFS DE LA SEMAINE 1

Objectif	Status	Détails
Setup projet	✓ FAIT	Structure complète + Git
Documentation	✓ FAIT	README + PROJECT_OVERVIEW
Environnement	✓ FAIT	Venv + requirements.txt
Dataset	✓ FAIT	112k images téléchargées
EDA	✓ FAIT	Notebook complet avec visualisations

Résultat : 100% des objectifs de la Semaine 1 ont été atteints. Le projet est parfaitement en phase avec le planning prévu.

3. RÉALISATIONS DÉTAILLÉES

3.1. Configuration du Projet

Création d'une structure de projet professionnelle suivant les meilleures pratiques du développement machine learning. Organisation modulaire permettant une maintenance facile et une collaboration efficace.

- **src/** : Code source Python (data, models, training, api, utils)
- **notebooks/** : Jupyter notebooks pour EDA et expérimentation
- **tests/** : Tests unitaires et d'intégration
- **docker/** : Configurations Docker et docker-compose
- **docs/** : Documentation technique complète
- **data/** : Dataset et fichiers de données (gitignore)
- **models/** : Modèles entraînés (.pth files)
- **frontend/** : Application React (préparé)

3.2. Setup Environnement Technique

Configuration complète de l'environnement de développement avec gestion des dépendances via environnement virtuel Python et fichier requirements.txt versionné.

Composant	Version/Détail
Python	3.11
PyTorch	2.1.0 (avec support CUDA)
FastAPI	0.104.1
MLflow	2.8.1
React	18 (préparé)
Docker	Configuré (docker-compose)
GPU	NVIDIA GeForce (détecté)

3.3. Téléchargement du Dataset

Téléchargement réussi du dataset complet ChestX-ray14 depuis la source officielle du NIH Clinical Center. Le dataset a été vérifié, décompressé et organisé selon la structure requise pour l'entraînement.

Métrique	Valeur
Source	NIH Clinical Center (officielle)
Nombre total d'images	112,120 radiographies
Résolution	1024×1024 pixels

Format	PNG (niveaux de gris, 8-bit)
Taille totale	~42 GB décompressé
Structure	12 dossiers (images_001 à images_012)
Fichier labels	Data_Entry_2017.csv (112,120 entrées)

3.4. Exploration des Données (EDA)

Analyse exploratoire complète du dataset réalisée dans un Jupyter notebook professionnel. L'EDA a permis de comprendre en profondeur la distribution des données, identifier les déséquilibres de classes et valider la qualité du dataset.

Analyses Réalisées :

- **Chargement et vérification** : Validation de l'intégrité des 112,120 images
- **Distribution des pathologies** : Analyse des 14 pathologies + No Finding
- **Visualisations statistiques** : Graphique en barres de la distribution
- **Échantillonnage d'images** : Affichage de 6 radiographies avec labels
- **Analyse des dimensions** : Vérification des résolutions (1024×1024)
- **Identification du déséquilibre** : No Finding = 53.84% du dataset

Résultats Clés :

Pathologie	Nombre	Pourcentage
No Finding	60,361	53.84%
Infiltration	19,894	17.74%
Effusion	13,317	11.88%
Atelectasis	11,559	10.31%
Nodule	6,331	5.65%
... (9 autres)	...	...
Hernia	227	0.20%

4. LIVRABLES DE LA SEMAINE

Livrable	Fichier/Dossier	Status
Repository GitHub	github.com/syrinetrabelsigit/radisense-ai	✓
Documentation principale	README.md	✓
Architecture projet	PROJECT_OVERVIEW.md	✓
Notebook EDA	notebooks/01_data_exploration.ipynb	✓
Script téléchargement	src/data/download_sample.py	✓
Script preprocessing	src/data/preprocessing.py	✓
Fichier dépendances	requirements.txt	✓
Configuration Git	.gitignore	✓
Dataset complet	data/raw/ (112k images)	✓

Historique Git : 8 commits effectués avec messages descriptifs, documentation des changements et respect des conventions de nommage.

5. MÉTRIQUES ET STATISTIQUES

5.1. Statistiques Dataset

Métrique	Valeur
Images totales	112,120
Images normales (No Finding)	60,361 (53.84%)
Images avec pathologies	51,759 (46.16%)
Pathologies uniques	14
Images multi-label	~30% (estimation)
Résolution moyenne	1024×1024 pixels
Format uniforme	PNG grayscale 8-bit

5.2. Métriques de Développement

Métrique	Valeur
Lignes de code Python	~500
Fichiers créés	25+
Commits Git	8
Tests écrits	Prévu Semaine 2
Couverture documentation	100%
Temps total investi	~12 heures

6. DIFFICULTÉS RENCONTRÉES ET SOLUTIONS

Difficulté	Solution Appliquée	Résultat
Taille du dataset (42 GB)	Téléchargement nocturne via Kaggle API	✓ Téléchargement complet réussi
Fichier .zip corrompu lors de l'extraction Windows	Utilisation de WinRAR au lieu de l'extracteur Windows	✓ Extraction complète sans erreur
Structure dataset imbriquée (images dans sous-dossiers)	Adaptation du code de lecture avec glob patterns récursifs	✓ Toutes les images accessibles
Configuration Kaggle API	Création manuelle du fichier kaggle.json dans .kaggle/	✓ API fonctionnelle
Espace disque limité (120 GB disponibles)	Suppression des fichiers .zip après extraction	✓ 84 GB libérés

Leçons apprises : L'utilisation d'outils alternatifs (WinRAR) et la planification de téléchargements longs pendant la nuit permettent de contourner efficacement les contraintes techniques. La vérification systématique de l'intégrité des fichiers téléchargés est essentielle.

7. VALIDATION DES OBJECTIFS

Tous les objectifs définis pour la Semaine 1 dans le planning initial ont été atteints avec succès. Le projet est en parfaite conformité avec le cahier des charges du professeur et les exigences du module Deep Learning.

Critère de Validation	Exigence	Status
Structure projet	Organisée et documentée	✓ VALIDÉ
Repository Git	Commits réguliers avec messages clairs	✓ VALIDÉ
Dataset téléchargé	ChestX-ray14 complet (112k images)	✓ VALIDÉ
EDA réalisé	Notebook avec analyses et visualisations	✓ VALIDÉ
Documentation	README + PROJECT_OVERVIEW complets	✓ VALIDÉ
Environnement technique	Python 3.11 + packages installés	✓ VALIDÉ
GPU disponible	NVIDIA détecté pour entraînement	✓ VALIDÉ
Conformité planning	Respect du planning 8 semaines	✓ VALIDÉ

Conclusion : La Semaine 1 constitue une base solide et complète pour la suite du projet. Toutes les fondations techniques et méthodologiques sont en place pour attaquer efficacement les phases de preprocessing et d'entraînement des modèles.

8. PROCHAINES ÉTAPES - SEMAINE 2

La Semaine 2 sera consacrée au développement du pipeline de preprocessing et à la préparation des données pour l'entraînement des modèles. Cette phase est critique pour assurer la qualité des inputs et l'efficacité de l'apprentissage.

Objectifs Semaine 2 :

Tâche	Livrable Attendu	Priorité
Pipeline preprocessing complet	Script preprocessing.py avec normalisation, resize	HAUTE
Data augmentation	Module augmentation.py avec transformations	HAUTE
Train/Val/Test split	Fichiers splits (80/10/10) + validation	HAUTE
PyTorch Dataset class	ChestXrayDataset custom class	HAUTE
DataLoaders	Train/Val/Test DataLoaders configurés	HAUTE
Setup MLflow	MLflow tracking server opérationnel	MOYENNE
Premier baseline model	VGG-16 baseline entraîné	MOYENNE
Notebook preprocessing	02_preprocessing.ipynb documenté	MOYENNE

Jalons Importants :

- **Jour 1-2 :** Développement du pipeline preprocessing
- **Jour 3-4 :** Implémentation data augmentation + DataLoaders
- **Jour 5-6 :** Configuration MLflow + premier baseline
- **Jour 7 :** Tests et validation du pipeline complet

CONCLUSION GÉNÉRALE

La Semaine 1 du projet RadiSense AI s'est déroulée avec un succès complet. L'infrastructure du projet est en place, le dataset est prêt à être exploité, et l'analyse exploratoire a révélé des insights précieux sur la nature des données. La détection d'un GPU NVIDIA fonctionnel est un atout majeur qui permettra d'entraîner les 5 modèles localement avec des performances optimales. Le déséquilibre des classes identifié lors de l'EDA (53.84% de No Finding) devra être pris en compte dans la stratégie d'entraînement, possiblement via du weighted sampling ou des techniques de class balancing. Le planning est respecté et toutes les fondations sont solides pour aborder sereinement les phases techniques plus avancées. La documentation exhaustive produite facilitera la maintenance du code et la compréhension du projet par le professeur lors de l'évaluation.

Rapport généré automatiquement par RadiSense AI Reporting System
Date : 15/02/2026
Statut : Semaine 1 COMPLÉTÉE ✓